

Pardavimų ir klientų elgsenos analizė

Supermarket Sales Dataset

Analitinių rezultatų santrauka ir verslo rekomendacijos

1. Aprašomosios analizės (EDA) radiniai

Duomenų rinkinį sudaro 1 000 pardavimo įrašai iš 3 filialų, apimantys 2019 m. sausį–kovą. Duomenų kokybė aukšta — trūkstančių ar pasikartojančių reikšmių neaptikta. Išskirtinės EDA įžvalgos:

- Pardavimų pasiskirstymas yra dešinien pasviręs:** didumos pirkinių vertė svyruoja tarp 100–300 USD, o dideli pirkimai virš 800 USD pasitaiko retai. Vidurkis (322,97) yra aukščiau medianos (253,85), o tai patvirtina išskirtų ir ilgos dešinės uodegos buvimą.
- Filialai veikia panašiai:** „Alex“, „Giza“ ir „Cairo“ filialų pardavimų mediana ir kvantiliai beveik identiški. Statistiškai reikšmingų skirtumų tarp filialų nėra (ANOVA $p = 0,41$).
- Produkto linijų poveikis nedidelis:** „Home and lifestyle“ ir „Sports and travel“ generuoja šiek tiek didesnius vidutinius pardavimus, tačiau skirtumai yra mažas ir praktiškai nežymūs.
- Savaitgalio efektas:** šeštadienį ir sekmadienį vidutiniai pardavimai yra didesni nei darbo dienomis, kas rodo jog turėtume stiprinti savaitgalio pardavimo kampanijas.

2. Pasikliautinyasis intervalas (95 %)

Pardavimų vidurkio 95 % pasikliautinyasis intervalas:

Rodiklis	Reikšmė
Imties vidurkis	322,97 USD
95 % CI apatinis švelšojų	310,17 USD
95 % CI viršutinis švelšojų	335,77 USD

Interpretacija: su 95 % tikimybe tikrasis pardavimų vidurkis yra tarp 310 ir 336 USD. Tai reiškia, kad tipiškas pirkimas generuoja apie 300–340 USD pardavimų. Verslas gali šiuo intervalu remtis planuodamas mėnesines pajamų prognozes (pvz., 1 000 klientų $\times$ 322,97 $\approx$ 323 000 USD per laikotarpį).

3. Hipotezių testavimo išvados

3.1 Nariai vs. paprasti pirkėjai (t-testas)

Rodiklis	Reikšmė
H ₀	Narių ir paprastų pirkėjų vidutiniai pardavimai yra lygūs
H _a	Skiriasi
Narių vidurkis	335,74 USD
Paprastų pirkėjų vidurkis	306,37 USD
Skirtumas	+29,37 USD
p reikšmė	0,0611
Išvada	H ₀ nėra atmetama ($\alpha = 0,05$)

Nors nariai vidutiniškai išleidžia ~29 USD daugiau, šis skirtumas yra statistiškai nepatikimas ($p = 0,06 > 0,05$). Tai verslo tendencija, verta stebėjimo, bet reikia daugiau duomenų.

3.2 Filialų pardavimai (ANOVA)

Rodiklis	Reikšmė
H ₀	Visų filialų vidutiniai pardavimai lygūs
F-statistika	0,8846
p reikšmė	0,4132
Išvada	H ₀ neatsmetama — filialai statistiškai nesiskiria

Vienodi filialų rezultatai rodo tolygiai veikiančias centrines strategijas ir nereikia atskirų korekcijų kiekvienam filialui

3.3 Lytis ir mokėjimo būdas (Chi-kvadratas)

Rodiklis	Reikšmė
H ₀	Lyties ir mokėjimo būdo ryšio nėra
χ^2 statistika	3,5758
p reikšmė	0,1673
Laisvės laipsnių	2
Išvada	H ₀ neatmetama — ryšio nėra

Lytis nesusijusi su mokėjimo būdu, todėl mokėjimo infrastruktūra gali būti vienoda visiems, o rinkodaros segmentavimui geriau naudoti kitus kintamuosius.

4. Regresinės analizės rezultatai

OLS modelis buvo apmokytas su 8 kintamaisiais (skaitiniais ir kategoriniais). Duomenys padalinti 80/20 train/test santykiu.

4.1 Modelio kokybės metrikos (testavimo rinkinys)

Metrika	Reikšmė
R ² (determinacijos koef.)	0,9019
MAE (vidutinis absoliutus nukrypimas)	59,38 USD
RMSE (šaknis iš vid. kvadrat. klaidos)	79,90 USD

Modelis paaiškina 90,2 % pardavimų variacijos. Toks aukštas R² ($\geq 0,90$) mažmeninėje prekyboje dažniausiai signalizuoja apie duomenų nutekėjimą (angl. data leakage). Tikėtina priežastis: Sales = Unit price $\times$ Quantity $\times$ 1,05 (su PVM), todėl Unit price ir Quantity matematiškai nulemia target kintamąjį — modelis iš esmės atkuria formulę, o ne atranda realius dėsningumus. Patikimesniam modeliui rekomenduojama pašalinti Unit price ir Quantity iš features arba rinktis kitą target kintamąjį (pvz., gross income arba Rating).

4.2 Svarbiausi koeficientai

Kintamasis	Koeficientas / Interpretacija
Quantity (+58,07)	Kiekvienas papildomas vienetas padidina pardavimus ~58 USD. Pagrindinis pardavimų variklis.
Unit price (+5,81)	Brangesnis produktas generuoja proporcingai didesnius pardavimus. Svarbu kainodaros optimizavimui.
Payment: Credit card (+9,97)	Kreditinėmis kortelėmis moką klientai išleidžia vidutiniškai ~10 USD daugiau, tačiau p = 0,17 — nepatikima.

5. Laiko eilučių analizė

Dienos pardavimai buvo agreguoti pagal datą, o 7 dienų slenkantis vidurkis naudotas svyravimams išlyginti.

Stebėjimas	Detalės
Bendra tendencija	Pardavimai 2019 m. sausį–kova išlieka stabilūs, būdinga ilgalaikės augimo ar mažėjimo tendencijos nenustatyta.
Kintamumas	Dienos pardavimai labai svyruoja; 7-dienė slenk. vidurkio kreivė parodo 200–1000 USD/d. intervalus.
Prognozė (paskutinių 7 d. vidurkis)	~4 249 USD/dienai — ši paprasta prognozė tinka naudoti kaip atskaitos taškas trumpalaikių operacijų prognozėms.
Savaitgalio efektas	Šeštadienis ir sekmadienis nuosekliai viršija darbo dienų vidurkius.

Matoma stabili dinamika, didelių dienos svyravimų normalumas mažmeninėje prekyboje, aiškus savaitgalio efektas ir prognozės apribojimai (tik 3 mėnesiai, be sezoninio konteksto).

6. Verslo rekomendacijos

Remiantis analizės rezultatais, pateikiamos trys prioritetinės rekomendacijos:

1

Kainodaros optimizavimas (Unit price)

Unit price yra vienintelis statistiškai patikimas ir leakage neveikiamas pardavimų variklis (koef. +5,81, $p < 0,001$). Tai reiškia, kad kiekvienas papildomas doleris produkto kainoje generuoja proporcingai didesnius pardavimus — klientai nėra itin jautrūs kainai. Rekomenduojama išplėsti premium produktų asortimentą Home and lifestyle bei Sports and travel linijose, kurios jau dabar rodo aukštesnius vidutinius pardavimus. Papildomai verta išbandyti psichologinę kainodarą (pvz., 49,99 vietoj 50,00) ir palyginti konversijos rodiklius tarp filialų.

2

Savaitgalio tikslinės akcijos pagal produktų linijas

Duomenys aiškiai rodo, kad šeštadienis ir sekmadienis nuosekliai viršija darbo dienų pardavimų vidurkius visuose trijuose filialuose. Tai reiškia, kad savaitgaliais filialai sulaukia aktyvesnių ir didesnę perkamąją galią turinčių klientų. Rekomenduojama sukurti specialų savaitgalio asortimentą iš Home and lifestyle ir Sports and travel kategorijų — dvigubas efektas: aukščiausi pardavimai šiose linijose sutampa su aukščiausiu dienos srautu. Praktiškai: savaitgalio el. pašto kampanijos, socialinės medijos skelbimai penktadienio vakarą, riboto laiko pasiūlymai šeštadienį. Rekomenduojama A/B testuoti bent 4 savaites, kad rezultatai būtų statistiškai palyginami.

Narių programos pertvarka — aktyvus eksperimentas, ne laukimas

Dabartinė analizė rodo, kad nariai išleidžia ~29 USD daugiau nei paprasti pirkėjai, tačiau $p = 0,061$ — vos už reikšmingumo ribos. Užuot tiesiog kaupus daugiau duomenų pasyviai, rekomenduojama aktyviai paveikti šį skirtumą: įvesti ekskluzyvines narių nuolaidas savaitgaliais (kur srautas didžiausias), kad skirtumas tarp grupių augtų. Jei po 3 mėnesių su $\geq 2\,000$ įrašų p -reikšmė peržengs 0,05 ribą — lojalumo programa patvirtinta duomenimis ir verta plėsti. Jei ne — programa reikalauja esminės pertvarkos arba atsisakymo. Taip iš „stebėjimo“ tampa „testuokime ir spęskime“.

Analizė atlikta Python aplinkoje naudojant pandas, scipy, scikit-learn įrangos bibliotekas.

Duomenų šaltinis: Supermarket Sales Dataset (Kaggle, CC 0)